

XGBoost, SMOTE ve SHAP Etkileşim Analizi Kullanılarak Veri Sızıntısından Arındırılmış Çok Sınıflı Kronik Böbrek Hastalığı Evrelemesi

ÖZ

Kronik böbrek hastalığı (KBH), ilerleyici seyri ve çoğu zaman sessiz başlaması nedeniyle erken tanı ve risk sınıflandırması açısından kritik bir klinik sorundur. KBH, 2040 yılına kadar yıllık beş milyonu aşkın ölüme yol açması öngörülen küresel bir sağlık sorunudur. Yakın zamanlı çalışmalar KBH tahmininde yüksek performans (0.867 AUC-ROC) rapor etse de, evre sınırlarını tanımlayan eGFR ve serum kreatinin değerlerini girdi olarak kullanmaları nedeniyle ciddi bir veri sızıntısı (data leakage) barındırmaktadır. Bu çalışma; veri sızıntısından arındırılmış, sınıf dengesizliği giderilmiş ve KDIGO 2012 rehberlerine uygun beş sınıflı (Evre 1–5) bir KBH evreleme modeli geliştirmeyi amaçlamaktadır. Projede UCI Makine Öğrenmesi Deposu'ndan alınan 24 klinik değişkenli KBH veri seti kullanılmıştır. Veri sızıntısını önlemek amacıyla eGFR ve serum kreatinin modelden tamamen çıkarılmış; eksik veriler dağılım-duyarlı imputasyon stratejisiyle tamamlanmış; sınıf dengesizliği SMOTE yöntemiyle giderilmiştir. GridSearchCV ile optimize edilen XGBoost modeli ağırlıklı $F1 = 0.59$ ve $AUC-ROC = 0.808$ elde etmiştir. SHAP etkileşim analizi, hipoalbuminemi ve hipertansiyonun Evre 4–5 tahmini üzerindeki sinerjik riskini niceliklemiştir. Bulgular, metodolojik bütünlüğün yüzeysel metrik optimizasyonundan üstün olduğunu ve sızıntısız çok sınıflı modellemenin klinik uygulanabilirlik açısından belirgin avantaj sunduğunu ortaya koymaktadır.

Anahtar Kelimeler: Kronik Böbrek Hastalığı, Veri Sızıntısı, SMOTE, SHAP, XGBoost, Çok Sınıflı Sınıflandırma, KDIGO 2012

1. Giriş

Kronik böbrek hastalığı (KBH), dünya genelinde giderek artan yaygınlığı, mortaliteyle ilişkisi ve sağlık sistemleri üzerindeki ekonomik yükü nedeniyle önemli bir halk sağlığı sorunudur [1, 2]. KBH, tüm yetişkin nüfusun yaklaşık %10–15'ini etkilemekte; 2017 yılı itibarıyla 1,2 milyon ölümden sorumlu tutulmaktadır [3]. Hastalığın erken evrelerde çoğunlukla asemptomatik seyretmesi, tanının gecikmesine ve birçok hastanın anlamlı böbrek fonksiyon kaybı geliştikten sonra klinik değerlendirmeye girmesine yol açmaktadır [4]. Bu nedenle, KBH'nin erken dönemde saptanması ve hastaların doğru risk katmanlarına ayrılması klinik yönetim açısından büyük önem taşımaktadır.

Geleneksel KBH risk modelleri çoğunlukla yaş, cinsiyet, hipertansiyon, diyabet ve rutin laboratuvar bulguları gibi klasik klinik değişkenlere dayanmaktadır [5]. Makine öğrenmesi (ML) yöntemlerinin KBH tahminine uygulandığı çalışmalar son yıllarda hız kazanmış; sistematik derlemeler ve meta-analizler, söz konusu modellerin geleneksel istatistiksel yaklaşımlara kıyasla çeşitli avantajlar sunduğunu göstermiştir [6, 7, 8]. Bununla birlikte bu modellerin klinik karar verme süreçlerinde güvenle benimsenebilmesi için yalnızca tahmin üretmeleri değil, kararlarını yorumlanabilir biçimde açıklamaları da gerekmektedir [9].

Zheng ve ark. (2024) [3] tarafından yayımlanan çalışmada hem sınıflandırma hem de sağkalım analizi düzleminde çoklu algoritmaların karşılaştırılması bakımından önemli bir katkı sunulmuştur. Ancak bu çalışmada KBH evrelerini tanımlamak için kullanılan eGFR ve serum kreatinin (SK) değerleri doğrudan birer girdi özelliği olarak kullanılmıştır. Bir hastanın Evre 3'e girmesi, tanım gereği eGFR'nin $60 \text{ mL/dak/1,73 m}^2$ sınırının altına düşmesi demektir [10]. Dolayısıyla bu modeli eğitmek, bir kategori sınırını tahmin etmek için o sınırı yaratan formülün kendisini kullanmak — yani sonuç-tanımlama sızıntısı (data leakage) — anlamına gelmektedir.

Literatürdeki çalışmaların büyük çoğunluğu, KBH durumunu ikili bir sınıflandırma problemi olarak ele almaktadır [6, 11, 12]. Oysa klinik pratikte, hastanın Evre 3'te mi yoksa Evre 4'te mi olduğunu bilmek; tedavi yoğunluğu, ilaç seçimi ve refere kararı üzerinde doğrudan belirleyici bir etkiye sahiptir. İkili modeller bu ayrımı bütünüyle ortadan kaldırarak klinisyenlere gerçek anlamda yol gösterici bir değer

sunamaz. Gerçek dünya KBH kohortlarında yüksek evre hastalar sayısal olarak azınlıkta kalmakta; bu asimetrik yapı, ağırlıklandırılmamış metrikler kullanıldığında modelin azınlık sınıflarını gözden kaçırmaya neden olmaktadır [13, 14]. Khalid ve ark. (2024), söz konusu sorunların sistematik biçimde ele alınmasını alandaki en öncelikli araştırma ajandası olarak tanımlamıştır [12].

Bu çalışmanın amacı; veri sızıntısından arındırılmış, sınıf dengesizliğinin aşıldığı ve KDIGO 2012 rehberlerine [10] uygun beş sınıflı (Evre 1–5) bir ML metodolojisi sunmaktır. XGBoost algoritması ve SHAP etkileşim değerleri kullanılarak, rutin biyobelirteçler üzerinden KBH evresini eGFR bağımlılığı olmaksızın tahmin eden şeffaf ve güvenilir bir model geliştirilmesi hedeflenmektedir.

2. Materyal ve Yöntemler

2.1 Veri Seti ve Ön İşleme

Çalışmada, UCI Makine Öğrenmesi Deposu'ndan kamuya açık olarak erişilebilen KBH veri seti kullanılmıştır [15]. Bu veri seti, KBH araştırmalarında geniş kabul görmüş ve ML modellemesi için standart bir kıyaslama platformu işlevi kazanmıştır [14, 16, 17]. KBH tanısı bulunmayan bireyler analiz dışı bırakılmış; $n = 250$ doğrulanmış KBH hastasından oluşan bir kohort elde edilmiştir. Veri seti; yaş, kan basıncı, özgül ağırlık, albümin, şeker, kırmızı kan hücreleri, irinli hücreler, idrar bakteri varlığı, kan glukozu, kan üresi, serum kreatinin, sodyum, potasyum, hemoglobin, hematokrit, lökosit ve eritrosit sayısı, hipertansiyon, diabetes mellitus, koroner arter hastalığı, iştah, ödem ve anemi dahil olmak üzere 24 klinik ve laboratuvar değişkeni içermektedir.

Eksik değerler, Sterne ve ark. (2009) [17]'yi izleyen dağılım-duyarlı bir strateji ile doldurulmuştur. Normallik Kolmogorov-Smirnov testi ile değerlendirilmiş; normal dağılım gösteren sürekli değişkenler aritmetik ortalama, sağa çarpık değişkenler medyan, kategorik değişkenler ise mod ile tamamlanmıştır.

2.2 Özellik Mühendisliği: eGFR Hesaplaması ve KDIGO Evrelemesi

eGFR, MDRD formülü [18] kullanılarak serum kreatinin ve yaştan hesaplanmıştır:

$$\text{eGFR} = 175 \times (\text{Serum Kreatinin})^{-1.154} \times (\text{Yaş})^{-0.203}$$

Beş KBH evresi, KDIGO 2012 eşiklerine [10] göre atanmıştır: Evre 1 ($\text{eGFR} \geq 90$), Evre 2 ($60 \leq \text{eGFR} < 90$), Evre 3 ($30 \leq \text{eGFR} < 60$), Evre 4 ($15 \leq \text{eGFR} < 30$) ve Evre 5 ($\text{eGFR} < 15$). Etiket atanmasının ardından hem eGFR hem de serum kreatinin, özellik matrisinden kalıcı olarak çıkarılmıştır.

2.3 Keşifsel Veri Analizi

KBH kohortundaki dağılımları ve evreler arası klinik eğilimleri tanımlamak amacıyla kapsamlı bir keşifsel veri analizi (EDA) uygulanmıştır. Sınıf dengesizliğini nicelikleştirmek için evre dağılımı çubuk grafiği; evreler genelinde hemoglobin, sodyum, kan üre azotu ve kan basıncı için kutu grafikleri; hipertansiyon ve diabetes mellitus prevalansı için yığılmış çubuk grafikler; eksik veri tamamlık matrisi; Pearson korelasyon ısı haritası ve dağılım histogramları gibi analizler gerçekleştirilmiştir.

2.4 Veri Sızıntısının Önlenmesi

eGFR, tanım gereği evre sınırlarını doğrudan belirlemektedir; serum kreatinin ise birincil MDRD formülü girdisi olup yapısal olarak sonuçla eş-doğrusal ilişkidir [19]. Bu nedenle her ikisi de özellik setinden çıkarılmıştır. Geliştirilen model, KBH evresini tanımlayıcı böbrek fonksiyon ölçütlerini kullanmaksızın yalnızca 22 ikincil klinik ve laboratuvar değişkeninden tahmin etmeye zorlanmıştır. Bu metodolojik seçim, gerçek bir klinik senaryoyu temsil etmekte ve modelin pratik faydasını doğrudan desteklemektedir [7, 20].

2.5 Model Geliştirme ve Hiperparametre Optimizasyonu

Hedef değişken beş sınıflı evre etiketi (1–5) olarak belirlenmiştir. Kategorik değişkenler ikili tam sayılara eşlenmiş; veri seti 5-katlı çapraz doğrulama ile %80/%20 oranında bölünmüştür. İki sınıflandırıcı eğitilmiştir: Rastgele Orman [21] ($n_estimators=200$, $class_weight='balanced'$) ve GridSearchCV ile optimize edilmiş XGBoost [22]. SMOTE + XGBoost hattında sentetik örnekleme yalnızca eğitim bölümüne uygulanmıştır. Model performansları ağırlıklı F1 skoru, çok sınıflı AUC-ROC, evre bazlı sınıflandırma raporu ve karışıklık matrisi ile değerlendirilmiştir.

2.6 SHAP Yorumlanabilirlik Analizi

SHAP (SHapley Additive exPlanations) [9], shap.TreeExplainer aracılığıyla uygulanmıştır. Küresel özellik önemi çubuk özet grafikleriyle özetlenmiş; Evre 5'e özgü önem beeswarm grafikleriyle incelenmiştir. SHAP etkileşim değerleri hesaplanmış; serum albümin ve kan basıncı etkileşimi ayrıntılı biçimde analiz edilmiştir.

3. Bulgular

3.1 Keşifsel Veri Analizi

KBH hasta kohortu ($n = 250$), belirgin evre dengesizliği sergilemiştir. Evre 3 en büyük alt grubu oluşturmuştur (%30,0), bunu Evre 5 (%26,4) ve Evre 4 (%25,6) izlemiştir. Evre 1 ve 2 sırasıyla %8,4 ve %9,6 oranında temsil edilmiştir (Şekil 1).

Kutu grafiği analizi (Şekil 2), köklü nefroloji literatürüyle tutarlı monoton biyobelirteç gradyanları ortaya koymuştur [2, 23]. Hemoglobinin, Evre 1'den Evre 5'e doğru ilerleyici bir düşüş sergilemiş; kan üre azotu Evre 3'ten itibaren belirgin artış göstermiştir. Yığılmış çubuk grafikler (Şekil 3), hipertansiyon prevalansının Evre 1'de yaklaşık %10'dan Evre 5'te %75'in üzerine çıktığını ve yükselen bir diabetes mellitus gradyanı bulunduğunu doğrulamıştır [4, 24].

Pearson korelasyon analizi (Şekil 5), eGFR-evre korelasyonunu $r = -0,87$ ve SC-evre korelasyonunu $r = +0,49$ olarak hesaplamıştır; bu değerler sızıntı önlemenin ampirik gerekçesini sunmaktadır. Dağılım analizi (Şekil 6), hemoglobinin yaklaşık normal dağılım; kan üre azotunun güçlü sağa çarpıklık; sodyumun ise leptokurtik bir dağılım sergilediğini ortaya koymuştur [17].

3.2 Model Performansı: Genel Metrikler

Temel Rastgele Orman sınıflandırıcısı ortalama ağırlıklı F1 skoru %51,35 ($SS = 0,0489$) elde etmiştir. GridSearchCV optimizasyonunun ardından en iyi hat çapraz doğrulamada %58,22 ağırlıklı F1 skoru sağlamıştır. Ayrılmış test seti üzerinde ($n = 50$) SMOTE ile artırılmış XGBoost modeli %80,77 ağırlıklı AUC-ROC, %60 genel doğruluk, ağırlıklı $F1 = 0,59$ ve makro $F1 = 0,58$ değerlerine ulaşmıştır. Tablo 2, bu sonuçların literatürdeki temsili çalışmalarıyla karşılaştırmasını sunmaktadır.

Tablo 2: Temsili KBH Makine Öğrenmesi Çalışmalarıyla Performans Karşılaştırması

Çalışma	Yöntem	Görev	A-F1	AUC-ROC	Sızıntısız
Zheng ve ark. 2024 [3]	XGBoost + Sağkalım	İkili	R/Y	0.867	Hayır
Debal & Sitote 2022 [14]	Rastgele Orman	İkili	R/Y	0.993 *	Hayır
Islam ve ark. 2023 [16]	ML Topluluk	İkili	0.991 *	R/Y	Hayır
Mevcut Çalışma	XGBoost + SMOTE	5-Sınıf (Evre 1–5)	0.59	0.808	Evet

* Sonuç-tanımlama sızıntısı nedeniyle şişirilmiş değer (eGFR/SC yordayıcı olarak dahil edilmiş). R/Y: Raporlanmamış/Yok.

3.3 Evre Bazlı Sınıflandırma Performansı

Evre bazlı performans incelendiğinde Evre 5'in $F1 = 0,81$ (kesinlik = 0,79, duyarlılık = 0,85) ile tüm sınıfların en yüksek değerine ulaştığı görülmüştür; bunun nedeni son dönem böbrek hastalığının tartışmasız biçimde şiddetli bir biyokimyasal imza üretmesidir [23, 25]. Evre 1, küçük destek boyutuna ($n = 4$) karşın $F1 = 0,67$ elde etmiştir. En zorlu sınıflar Evre 4 ($F1 = 0,43$) ve Evre 2 ($F1 = 0,44$) olmuştur; bu iki evre biyobelirteç değerlerinin komşu evrelerle kısmen örtüştüğü geçiş bölgelerinde yer almaktadır.

3.4 Karışıklık Matrisi Analizi

Karışıklık matrisi (Şekil 9), model hatalarının klinik açıdan tabakalı bir görünümünü sunmaktadır. Kritik olarak uzak yanlış sınıflandırma hataları gözlemlenmemiştir: hiçbir Evre 1 hastası Evre 4 veya 5 olarak, hiçbir Evre 5 hastası ise Evre 1 veya 2 olarak tahmin edilmemiştir. Tüm hatalar komşu evre çiftleriyle sınırlı kalmış; bu örüntü modelin KBH'nin monoton patofizyolojik gradyanını öğrendiğini doğrulamaktadır [20].

3.5 SHAP Özellik Önemi ve Etkileşim Analizi

Küresel SHAP analizi (Şekil 7), kan üre azotunu (bu) en yüksek küresel etkiye sahip girdi olarak belirlemiştir. Yaş, hemoglobin (hemo), sodyum (sod) ve albümin (al) ikinci önem kademesini oluşturmuştur. Bu hiyerarşi mekaniksel olarak tutarlıdır: kan üre düzeyi, azalan glomerüler klirensin yol açtığı üremik çözünmüş madde birikimini ölçer ve bu nedenle KBH şiddetinin güçlü bir göstergesidir [2, 26].

Evre 5'e özgü beeswarm analizi (Şekil 8), yüksek kan üre azotu değerlerinin Evre 5 tahminine yönelik en büyük pozitif SHAP katkılarını ürettiğini ortaya koymuştur. Hemoglobin belirgin iki yönlü bir örüntü sergilemiştir: düşük hemoglobin (< 8 g/dL) güçlü bir pozitif sürücü oluştururken 12 g/dL'nin üzerindeki değerler koruyucu negatif SHAP değerleri üretmiştir.

SHAP etkileşim değeri analizi, serum albümin (al) ve kan basıncı (bp) arasındaki ikili sinerjisini nicelleştirmiştir. Eş zamanlı olarak düşük albümin ($< 3,5$ g/dL) ve yüksek kan basıncı (> 140 mmHg) sergileyen hastalarda Evre 4–5 tahminine yönelik bileşik SHAP katkısı, iki bağımsız marjinal değer toplamını yaklaşık 0,04–0,06 SHAP birimi aşmıştır.

4. Tartışma

4.1 Metodolojik Katkı: Sızıntısız Dürüst Tahmin

Bu çalışmanın temel katkısı, sonuç-tanımlama sızıntısının giderilmesinin model performansının hem niteliğini hem de bilgilendiricilik düzeyini değiştirdiğinin ortaya konmasıdır. Zheng ve ark. (2024) [3] tarafından bildirilen $AUC = 0,867$ kıyaslama değeri, kendi hedeflerinin matematiksel tanımını girdi özelliği olarak alan bir model tarafından üretilmiştir. Bu özellikler çıkarılıp görev gerçek anlamda tahminsel bir beş sınıflı problem olarak yeniden formüle edildiğinde, ulaşılabilir AUC %80,77'ye, ağırlıklı $F1$ ise 0,59'a yerleşmektedir. Bu sonuç performans gerilemeyi değil, daha önce şişirilmiş olan bir tabanın düzeltilmesini yansıtmaktadır.

4.2 Özgün SHAP Etkileşim Bulguları ve Klinik Çıkarımlar

SHAP etkileşim analizi, çalışmanın en özgün klinik katkısını oluşturmaktadır. Hipoalbüminemi ve hipertansiyon arasında 0,04–0,06 SHAP birimi düzeyinde nicelleştirilen sinerjik delta, belirgin patofizyolojik temeli olan toplamsal olmayan bir risk amplifikasyonunu temsil etmektedir. Hipoalbüminemi, onkotik basıncı azaltarak glomerüler hiperfiltrasyon döngüsünü beslerken; hipertansiyon glomerüler kılcal basıncı artırarak böbrek hasarını yoğunlaştırır. Bu iki süreç bir arada varlık gösterdiğinde farklı ancak sinerjik hasar yollarını devreye sokar [24, 27].

Klinik çıkarım eylem odaklıdır: eş zamanlı hipoalbuminemi ve yüksek kan basıncı sergileyen bir hastanın Evre 4–5 ilerleme riski orantısız biçimde yüksek kabul edilmeli; bu durum daha agresif kan basıncı kontrol hedeflerini ve beslenme kaynaklı albumin desteğini hak etmektedir [6, 9].

4.3 Kısıtlamalar

Mevcut sonuçların kapsamını dört kısıtlama sınırlamaktadır. Birincisi, tek merkezli kesitsel tasarım dış geçerliliği kısıtlamaktadır. İkincisi, veri seti boyutu ($n = 250$) beş sınıflı tahmin için yetersiz kalmaktadır. Üçüncüsü, basitleştirilmiş MDRD formülü cinsiyet düzeltme faktörünü atlamaktadır. Dördüncüsü, SHAP etkileşim deltası klinik çeviri öncesinde prospektif müdahale doğrulaması gerektirmektedir.

5. Sonuç

Bu çalışma, sızıntı önlemeyi, çok sınıflı granülariteyi, sınıf dengesizliği düzeltmesini ve etkileşim düzeyinde yorumlanabilirliği kapsayan metodolojik bütünlüğün, gerçek klinik önemi olan bir KBH makine öğrenmesi çerçevesi oluşturduğunu ortaya koymaktadır. SMOTE + XGBoost modeli, dürüst beş sınıflı tahmin kapsamında ağırlıklı $F1 = 0,59$ ve $AUC-ROC = \%80,77$ elde etmiştir. SHAP etkileşim analizi, hipoalbuminemi ve hipertansiyon arasında özgün bir sinerjik risk sinyali niceliklemiştir. Karışıklık matrisinde gözlemlenen hataların tüm komşu evre çiftleriyle sınırlı kalması, modelin KBH'nin patofizyolojik gradyanını anlamlı biçimde öğrendiğini kanıtlamaktadır.

Önerilen çerçeve, metrik şişirmek yerine klinik sadakate kendini adanmış KBH makine öğrenmesi araştırmaları için tekrarlanabilir bir metodolojik şablon oluşturmaktadır [7, 9, 21]. Gelecek çalışmalarda çok merkezli prospektif kohortların kullanılması, model genellenebilirliğini önemli ölçüde güçlendirecektir.

Teşekkür

Yazarlar, bu analizin temelini oluşturan açık kaynaklı KBH veri setini sağladıkları için UCI Machine Learning Repository'ye (University of California, Irvine) [15] teşekkür eder. Herhangi bir çıkar çatışması bulunmadığını beyan ederler.

Kaynakça

- [1] V. A. Luyckx, Z. Al-Aly, A. K. Bello ve ark., "Sustainable development goals relevant to kidney health: an update on progress," *Nature Reviews Nephrology*, cilt 17, ss. 15–32, 2021.
- [2] K. Kalantar-Zadeh, T. H. Jafar, D. Nitsch ve ark., "Chronic kidney disease," *The Lancet*, cilt 398, sy. 10302, ss. 786–802, 2021.
- [3] J.-X. Zheng, X. Li, J. Zhu ve ark., "Interpretable machine learning for predicting chronic kidney disease progression risk," *Digital Health*, cilt 10, ss. 1–16, 2024.
- [4] T. K. Chen, D. H. Knicely ve M. E. Grams, "Chronic kidney disease diagnosis and management: a review," *JAMA*, cilt 322, sy. 13, ss. 1294–1304, 2019.
- [5] L. A. Inker, B. C. Astor, C. H. Fox ve ark., "KDOQI US commentary on the 2012 KDIGO clinical practice guideline," *Am. J. Kidney Dis.*, cilt 63, sy. 5, ss. 713–735, 2014.
- [6] N. Lei, X. Zhang, M. Wei ve ark., "Machine learning algorithms' accuracy in predicting kidney disease progression," *BMC Medical Informatics and Decision Making*, cilt 22, s. 205, 2022.
- [7] F. Sanmarchi ve ark., "Predict, diagnose, and treat chronic kidney disease with machine learning," *J. Nephrol.*, cilt 36, ss. 1101–1117, 2023.
- [8] E. Dritsas ve M. Trigka, "Machine learning techniques for chronic kidney disease risk prediction," *Big Data Cogn. Comput.*, cilt 6, sy. 3, s. 98, 2022.
- [9] S. M. Lundberg ve S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in Neural Information Processing Systems (NeurIPS)*, cilt 30, 2017, ss. 4765–4774.
- [10] Kidney Disease: Improving Global Outcomes (KDIGO) CKD Work Group, "KDIGO 2012 Clinical Practice Guideline for the Evaluation and Management of Chronic Kidney Disease," *Kidney Int Suppl.*, cilt 3, ss. 1–150, 2013.
- [11] C. T. Su ve ark., "Machine learning models for the prediction of renal failure in CKD," *Diagnostics*, cilt 12, s. 2454, 2022.

- [12] F. Khalid ve ark., "Predicting the progression of chronic kidney disease: a systematic review," *Cureus*, cilt 16, s. e60145, 2024.
- [13] N. V. Chawla, K. W. Bowyer, L. O. Hall ve W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *J. Artif. Intell. Res.*, cilt 16, ss. 321–357, 2002.
- [14] D. A. Debal ve T. M. Sitote, "Chronic kidney disease prediction using machine learning techniques," *J. Big Data*, cilt 9, s. 109, 2022.
- [15] L. Rubini, P. Soundarapandian ve P. Eswaran, Chronic Kidney Disease Data Set [Veri Seti], UCI Machine Learning Repository, 2015.
- [16] M. A. Islam, M. Z. H. Majumder ve M. A. Hussein, "Chronic kidney disease prediction based on machine learning algorithms," *J. Pathol. Inform.*, cilt 14, s. 100189, 2023.
- [17] J. A. C. Sterne ve ark., "Multiple imputation for missing data in epidemiological and clinical research," *BMJ*, cilt 338, s. b2393, 2009.
- [18] A. S. Levey, J. P. Bosch, J. B. Lewis ve ark., "A more accurate method to estimate glomerular filtration rate from serum creatinine," *Annals of Internal Medicine*, cilt 130, sy. 6, ss. 461–470, 1999.
- cilt 2025, s. 8487716, 2025.
- [19] H. T. Lee ve ark., "Risk of data leakage in estimating the diagnostic performance," *Sci. Rep.*, cilt 13, s. 16633, 2023.
- [20] S. K. Ghosh ve A. H. Khandoker, "A machine learning driven nomogram for predicting CKD stages 3–5," *Sci. Rep.*, 2023.
- [21] L. Breiman, "Random forests," *Machine Learning*, cilt 45, sy. 1, ss. 5–32, 2001.
- [22] T. Chen ve C. Guestrin, "XGBoost: A scalable tree boosting system," 22. ACM SIGKDD Uluslararası Bilgi Keşfi ve Veri Madenciliği Konferansı Bildirileri, 2016, ss. 785–794.
- [23] J. L. Babitt ve H. Y. Lin, "Mechanisms of anemia in CKD," *Journal of the American Society of Nephrology*, cilt 23, sy. 10, ss. 1631–1634, 2012.
- [24] Y. Wang, L. Ran, M. Lan ve ark., "The effects of hypertension and diabetes on new-onset CKD," *J. Clin. Hypertens.*, cilt 22, sy. 3, ss. 1–9, 2020.
- [25] E. Palaka ve ark., "The impact of CKD anaemia on patients," *Int. J. Nephrol.*, cilt 2020, s. 7692376, 2020.
- [26] C. O. Ogolla ve ark., "Hematological biomarkers in predicting progression and complications of CKD," *Adv. Hematol.*,
- [27] S. Al-Shamsi, D. Regmi ve R. D. Govender, "Chronic kidney disease in patients at high risk of cardiovascular disease in the UAE," *PLoS One*, cilt 13, sy. 7, s. e0199920, 2018.